Program Studi Teknik Informatika
Institut Teknologi Sumatera

IF25-22014 PENGEMBANGAN APLIKASI WEB

Modul Belajar 13

AI pada Aplikasi Web

Menambahkan fitur model bahasa ke aplikasi dengan aman, terukur, dan jujur kepada pengguna

Tim Pengajar
Pengembangan Aplikasi Web. Tahun 2026

Komponen	Keterangan
Pertemuan	13 dari 16
Capaian	Sub-CPMK 13.1 dan 13.2, turunan CPMK0503
Waktu belajar	sekitar 3 jam belajar mandiri, ditambah 150 menit di kelas
Hands-on	`02 Hands-on/P13 - AI - Hands-on/`
Yang perlu disiapkan	FastAPI dan Next.js dari P11 dan P12; salah satu dari: Ollama terpasang dengan satu model kecil, kunci API penyedia model, atau mode tiruan

Peta belajar

Modul ini mengikuti bagian yang sama dengan slide. Setiap konsep inti ditulis dalam kotak gelap: itulah kalimat yang harus bisa kalian jelaskan ulang.

Bagian	Judul	Yang dipelajari
1	AI di aplikasi web	Mengenali fitur AI yang umum dan cara aplikasi memakainya
2	Memanggil model dari server	Memanggil API model dari FastAPI dengan kunci yang aman
3	Prompt dan keluaran terstruktur	Menulis prompt yang jelas dan memvalidasi jawaban model dengan Pydantic
4	Keamanan dan etika	Mengenali risiko fitur AI dan cara mengendalikannya
5	Antarmuka fitur AI	Merancang antarmuka yang jujur dan nyaman untuk fitur AI

Tentang modul ini

Modul ini menemani Pertemuan 13. Setiap kotak merah **Tebak dulu** meminta kalian menulis dugaan sebelum membaca kotak hijau **Jawaban** di bawahnya. Kerjakan contoh kode sambil membaca, jangan hanya dibaca.

Setelah menyelesaikan modul ini, kalian bisa

No	Kemampuan	Diukur di
13.1	Menjelaskan cara aplikasi web memakai model AI lewat API beserta risiko keamanan dan etikanya	Exit ticket soal 1, hands-on, proyek
13.2	Menerapkan fitur AI di FastAPI dan Next.js dengan keluaran terstruktur dan antarmuka yang jujur	Exit ticket soal 2, hands-on, proyek

Keduanya menurunkan CPMK0503: mahasiswa mampu menerapkan teknologi sistem cerdas dalam pengembangan perangkat lunak.

Masalah pembuka

Pengumuman yang terlalu panjang

Situs himpunan memuat pengumuman sepanjang dua halaman. Ketua himpunan ingin tombol *Ringkas* yang membuat tiga poin penting dan kategorinya.

Seorang anggota langsung menulis kode di samping, di komponen Next.js, lengkap dengan kunci API penyedia AI.

TEBAK DULU

Apa saja yang salah dengan rancangan ini, dari sisi keamanan, biaya, dan pengalaman pengguna?

```
"use client";
const KUNCI = "sk-rahasia-123...";
async function ringkas(teks) {
  const r = await fetch("https://api.penyedia.ai/v1/chat", {
    headers: { Authorization: `Bearer ${KUNCI}` },
    method: "POST",
    body: JSON.stringify({ pesan: teks }),
  });
  setHasil(await r.text());
}
```

Bagian 1: AI di aplikasi web

TUJUAN: MENGENALI FITUR AI YANG UMUM DAN CARA APLIKASI MEMAKAINYA

Model bahasa sebagai layanan

Large Language Model (LLM)

Model AI yang dilatih pada teks dalam jumlah sangat besar untuk memprediksi kelanjutan teks; dipakai lewat API untuk meringkas, mengklasifikasi, menjawab, atau mengubah format teks.

Bagi aplikasi web, model adalah satu server lagi di peta P1: kita mengirim request berisi teks, menerima response berisi teks. Bedanya, jawabannya tidak pasti sama setiap kali, bisa keliru dengan yakin, butuh waktu lebih lama, dan berbiaya per pemakaian.

Fitur AI yang umum

Fitur	Contoh di kampus	Bentuk keluaran
meringkas	pengumuman panjang menjadi tiga poin	list teks
mengklasifikasi	laporan fasilitas ke kategori dan prioritas	satu nilai dari daftar
mengekstrak	tanggal dan tempat dari undangan acara	object bertipe
menjawab dari dokumen	pertanyaan tentang pedoman akademik	teks dan rujukan
menyarankan	mata kuliah pilihan sesuai minat	list dengan alasan

Ingat

Fitur yang paling mudah dipercaya adalah yang keluarannya bisa diperiksa: kategori dari daftar, object dengan kolom jelas.

Inti Bagian 1

Aplikasi web memakai model AI lewat API seperti layanan lain: server mengirim teks, model membalas teks yang harus diperiksa.

Bagian 2: Memanggil model dari server

TUJUAN: MEMANGGIL API MODEL DARI FASTAPI DENGAN KUNCI YANG AMAN

Jangan dari browser

Salah: Next.js langsung

```
// semua kode client terkirim ke browser
const KUNCI = "sk-rahasia-123";
fetch("https://api.penyedia.ai/...", {
  headers: { Authorization:
    `Bearer ${KUNCI}` } });
```

Benar: lewat FastAPI

```
// Next.js
fetch("http://localhost:8000/ringkas", {
  method: "POST", body: JSON.stringify({ teks }),
  headers: { "Content-Type": "application/json" } });

# FastAPI membaca kunci dari .env
KUNCI = os.environ["LLM_API_KEY"]
```

Kode komponen klien dikirim utuh ke browser (P5), jadi kunci terlihat di tab Sources atau Network. Siapa pun bisa memakainya atas biaya kalian. Jawaban misi 2.

Klien LLM di FastAPI

```
import os, httpx

BASE = os.environ.get("LLM_BASE_URL", "http://localhost:11434/v1")
MODEL = os.environ.get("LLM_MODEL", "llama3.2")
KUNCI = os.environ.get("LLM_API_KEY", "")

async def tanya_llm(sistem: str, isi: str) → str:
    async with httpx.AsyncClient(timeout=60) as c:
        r = await c.post(f"{BASE}/chat/completions",
            headers={"Authorization": f"Bearer {KUNCI}"},
            json={"model": MODEL, "messages": [
                {"role": "system", "content": sistem},
                {"role": "user", "content": isi}]})
        r.raise_for_status()
        return r.json()["choices"][0]["message"]["content"]
```

Format *chat completions* dipakai banyak penyedia, termasuk Ollama untuk model di laptop sendiri. Ganti penyedia cukup dengan mengubah `.env`.

`httpx.AsyncClient`: klien HTTP asinkron; `async` dan `await` dari P6, versi Python.

Pesan `system` memberi aturan; pesan `user` berisi teks pengguna.

`timeout=60`: jawaban model bisa lama. `raise_for_status`: kode 4xx dan 5xx dari penyedia menjadi error di server kita.

Ikuti bersama: fitur AI dalam mode tiruan

Kerjakan sambil membaca, satu langkah demi satu langkah.

No	Langkah	Perintah atau kode
1	Salin konfigurasi contoh; di Windows pakai `copy`.	`cp .env.example .env`
2	Pastikan modenya tiruan.	`LLM_MODE=tiruan`
3	Jalankan server.	`fastapi dev main.py`
4	Di `/docs`, pilih `POST /ringkas`, isi teks minimal 50 karakter, Execute.	
5	Ganti ke `LLM_MODE=sungguhan` bila Ollama siap, simpan, ulangi.	

YANG HARUS TERLIHAT

Mode tiruan membalas dua poin contoh berkategori lainnya. Mode sungguhan membalas ringkasan dari model, atau 503 bila model belum berjalan.

Kalau berbeda

Mode tidak berubah: `.env` tidak terbaca; jalankan server dari folder yang sama dengan `.env`. 503 terus: jalankan `ollama serve` lalu `ollama pull llama3.2`.

Inti Bagian 2

Model selalu dipanggil dari server; kunci API di .env, alamat dan nama model di konfigurasi, dan pemanggilan memakai klien HTTP asinkron.

Bagian 3: Prompt dan keluaran terstruktur

TUJUAN: MENULIS PROMPT YANG JELAS DAN MEMVALIDASI JAWABAN MODEL DENGAN PYDANTIC

Minta JSON, lalu periksa

```
class Ringkasan(BaseModel):
    poin: list[str] = Field(min_length=1, max_length=3)
    kategori: Literal["akademik", "kegiatan", "beasiswa", "lainnya"]
SISTEM = """Kamu meringkas pengumuman kampus untuk mahasiswa.
Balas HANYA JSON: {"poin": [maks 3 kalimat], "kategori": salah satu
dari akademik, kegiatan, beasiswa, lainnya}. Jangan menambah fakta."""
@app.post("/ringkas", response_model=Ringkasan)
async def ringkas(m: TeksIn):
    jawaban = await tanya_llm(SISTEM, m.teks)
    try:
        return Ringkasan.model_validate_json(jawaban)
    except ValidationError:
        raise HTTPException(502, "Jawaban AI tidak sesuai format")
```

Jawaban misi 1: bentuk keluaran ditentukan dulu sebagai model Pydantic.

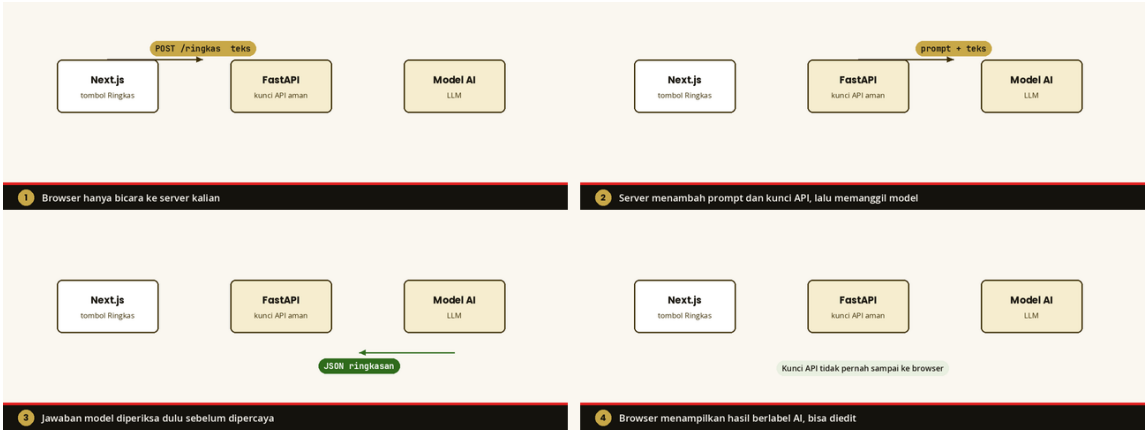
`Literal`: kategori hanya boleh salah satu dari daftar, jadi bisa ditampilkan sebagai label berwarna tanpa kejutan.

Prompt sistem menyebut peran, tugas, batasan (*jangan menambah fakta*), dan format persis.

`model_validate_json`: jawaban model diperlakukan seperti masukan pengguna, divalidasi dulu.

502 Bad Gateway: kesalahan dari layanan yang kita panggil, bukan dari pengguna (4xx) atau kode kita (500).

Alur fitur AI



Browser tidak pernah melihat kunci API, dan jawaban model diperiksa sebelum sampai ke pengguna. Versi bergeraknya ada di slide PowerPoint.

Kode status untuk gagal di model

TEBAK DULU

Penyedia model membalas 503 karena sibuk, sehingga endpoint `/ringkas` kalian tidak bisa menjawab. Kode status yang paling tepat untuk Next.js? (A) 200 dengan ringkasan kosong; (B) 422; (C) 502 atau 503; (D) 404

JAWABAN: C

Masalahnya di layanan hulu, bukan di request pengguna. 502 atau 503 memberi tahu frontend untuk menyarankan coba lagi nanti.

Inti Bagian 3

Prompt yang baik menyebut peran, tugas, batasan, dan format; minta JSON lalu validasi dengan Pydantic, dan balas 502 bila jawaban model tidak sesuai.

Bagian 4: Keamanan dan etika

TUJUAN: MENGENALI RISIKO FITUR AI DAN CARA MENGENDALIKANNYA

Risiko dan pengendaliannya

Risiko	Pengendalian
kunci bocor, tagihan membengkak	kunci hanya di server dan `.env`; batasi jumlah permintaan per pengguna, balas 429 bila lewat
prompt injection	teks pengguna bisa berisi *abaikan aturan sebelumnya*; jangan beri model wewenang langsung, validasi keluaran
data pribadi	jangan kirim NIM, nilai, atau kontak bila tidak perlu; pahami kebijakan data penyedia
halusinasi	jawaban keliru dengan yakin; minta model tidak menambah fakta, tampilkan sumber, biarkan manusia memeriksa
bias dan ketidakadilan	uji dengan contoh beragam; keputusan penting tetap di tangan manusia

Tiga baris yang salah

Yang ditulis	Mengapa salah, dan perbaikannya
kunci API di komponen `"use client"`	Terkirim ke setiap browser. Pindahkan pemanggilan ke FastAPI dan kunci ke `.env`.
`setHasil(await r.text())` langsung dari model	Jawaban tidak diperiksa; bisa bukan JSON atau berisi teks aneh. Validasi dengan model Pydantic di server.
tombol Ringkas tanpa batas	Satu orang bisa menekan ratusan kali atas biaya kalian. Matikan tombol saat memuat dan batasi di server.

Pola kesalahannya

Ketiganya ada di kode masalah minggu ini.

Inti Bagian 4

Lindungi kunci dan biaya, anggap teks pengguna bisa berisi perintah, jangan kirim data pribadi tanpa perlu, dan beri tahu pengguna bahwa hasil AI bisa salah.

Bagian 5: Antarmuka fitur AI

TUJUAN: MERANCANG ANTARMUKA YANG JUJUR DAN NYAMAN UNTUK FITUR AI

Pedoman antarmuka fitur AI

Pedoman	Wujudnya di React
tunjukkan sedang bekerja dan berapa lama biasanya	teks status *Meringkas, biasanya 5 sampai 15 detik* dengan `role="status"`
beri jalan keluar	tombol *Batal* yang menghentikan fetch dengan `AbortController`
beri label yang jujur	label *Dibuat AI, periksa sebelum dipakai* di atas hasil
biarkan pengguna mengoreksi	hasil ditampilkan di `<textarea>` terkendali yang bisa diedit sebelum disimpan
gagal dengan sopan	pesan `role="alert"`: apa yang gagal dan sarankan coba lagi, untuk 502 dan 503
kumpulkan umpan balik	tombol *berguna* dan *tidak berguna* di bawah hasil

Batal dan label di Next.js

```
const [memuat, setMemuat] = useState(false);
const kendali = useRef(null);
async function ringkas() {
  kendali.current = new AbortController();
  setMemuat(true);
  try {
    const r = await fetch(`${API}/ringkas`, { method: "POST",
      headers: { "Content-Type": "application/json" },
      body: JSON.stringify({ teks }), signal: kendali.current.signal });
    if (!r.ok) throw new Error(r.status);
    setHasil(await r.json());
  } catch (e) {
    if (e.name !== "AbortError") setGalat("Gagal meringkas. Coba lagi.");
  } finally { setMemuat(false); }
} // Batal: kendali.current?.abort()
```

Pola P6 dan P7 ditambah pembatalan.

`useRef` menyimpan `AbortController` tanpa menggambar ulang (hook dari P7).

`signal`: fetch berhenti saat `abort()` dipanggil; pembatalan tidak ditampilkan sebagai error.

Setelah hasil datang, tampilkan label AI dan teks yang bisa diedit.

Giliran kalian

SETENGAH JADI: KLASIFIKASI LAPORAN

Lengkapi model: `prioritas: _____["rendah", "sedang", "tinggi"]` dan di endpoint, bila validasi gagal, `raise HTTPException(____)`.

MANDIRI: BATAS PERMINTAAN

Tulis dependency sederhana yang menyimpan waktu permintaan per alamat IP di dict dan membalas 429 bila lebih dari 5 permintaan dalam 60 detik.

JAWABAN

Setengah jadi: Literal, 502. Mandiri: dict IP ke list waktu; buang yang lebih tua dari 60 detik; bila panjangnya 5 atau lebih, raise HTTPException(429); bila tidak, tambahkan waktu sekarang.

Inti Bagian 5

Tampilkan perkiraan waktu, sediakan batal, beri label AI, dan biarkan hasil diedit.

Latihan mandiri

Kerjakan lembar dan berkas awal di folder `02 Hands-on/P13 - AI - Hands-on/`.

Tingkat	Waktu	Yang dilatih
Tingkat 1, Dasar	10′	endpoint dengan model masukan dan keluaran dalam mode tiruan
Tingkat 2, Menengah	15′	memanggil model sungguhan, prompt sistem, validasi JSON, dan 502
Tingkat 3, Tantangan	10′	antarmuka Next.js: memuat, batal, label AI, edit, galat
Pengayaan	sisa	batas permintaan dan umpan balik pengguna

Kesalahan yang sering muncul

Yang ditulis	Masalahnya	Obatnya
kunci API di Next.js	bocor ke browser	panggil dari FastAPI, kunci di `.env`
jawaban model tidak divalidasi	format dan isi tak terduga	model Pydantic dan 502
tidak ada batas permintaan	biaya membengkak	batas per pengguna, 429
tombol tetap aktif saat memuat	permintaan berulang	matikan tombol, tampilkan perkiraan waktu
hasil AI tanpa label	pengguna mengira pasti benar	label dan bisa diedit
data pribadi dikirim ke model	risiko privasi	kirim seperlunya, pahami kebijakan penyedia

Rangkuman

No	Bagian	Inti
1	AI di aplikasi web	Aplikasi web memakai model AI lewat API seperti layanan lain: server mengirim teks, model membalas teks yang harus diperiksa.
2	Memanggil model dari server	Model selalu dipanggil dari server; kunci API di .env, alamat dan nama model di konfigurasi, dan pemanggilan memakai klien HTTP asinkron.
3	Prompt dan keluaran terstruktur	Prompt yang baik menyebut peran, tugas, batasan, dan format; minta JSON lalu validasi dengan Pydantic, dan balas 502 bila jawaban model tidak sesuai.
4	Keamanan dan etika	Lindungi kunci dan biaya, anggap teks pengguna bisa berisi perintah, jangan kirim data pribadi tanpa perlu, dan beri tahu pengguna bahwa hasil AI bisa salah.
5	Antarmuka fitur AI	Tampilkan perkiraan waktu, sediakan batal, beri label AI, dan biarkan hasil diedit.

Cek pemahaman

Jawab tanpa membuka modul atau slide. Mengingat kembali tanpa melihat lebih menguatkan ingatan daripada membaca ulang.

No	Soal
1	Mengapa jawaban model perlu divalidasi seperti masukan pengguna?
2	Apa isi pesan system dan user?
3	Kode status bila layanan model gagal?
4	Apa itu prompt injection?
5	Untuk apa AbortController?
6	Sebutkan dua pedoman antarmuka fitur AI.

KUNCI CEK PEMAHAMAN

(1) Formatnya tidak dijamin dan isinya bisa dipengaruhi teks pengguna. (2) System berisi aturan dan format; user berisi teks yang diproses. (3) 502 atau 503. (4) Teks pengguna yang berisi perintah untuk membelokkan aturan model. (5) Membatalkan fetch yang sedang berjalan saat pengguna menekan Batal. (6) Label hasil AI, perkiraan waktu, tombol batal, hasil bisa diedit, pesan gagal yang menyarankan coba lagi.

Bacaan lanjut

FastAPI, *Async* dan *Settings and Environment Variables*. HTTPX, *Async Support* (`python-httpx.org`). Ollama, dokumentasi kompatibilitas OpenAI (`ollama.com`). OWASP, *Top 10 for Large Language Model Applications*.